

# 딥러닝을 이용한 SMP 예측 모델 개발 및 시각화

## 요약

본 연구는 과거의 데이터를 바탕으로 SMP 예측을 가시적으로 확인하고, 경제적인 이익을 확보해주며 전력망의 안정성에 기여한다. SMP는 인공지능을 이용하여 예측할 수 있으며, 보다 정확한 예측 값을 얻기 위해서는 SMP에 크게 영향을 미치는 전력 수요, 연료비, 유가 등의 요인에 대한 변수 처리, 인공지능 학습 알고리즘 모델의 성능과 입력되는 데이터의 특징을 추출하는 전처리 과정이 핵심적인 역할을 한다. 이 연구에서는 Hybrid ARIMA LSTM(Long Short-Term Memory)을 학습 알고리즘 모델을 사용하여 SMP 예측한다.

## 1. 서론

### 1.1. 연구배경

우리나라는 에너지 대외 의존도가 높고 유가 변동에 의한 영향이 크기 때문에 안정적인 에너지 공급이 중요한 과제이다. 기존의 화석연료를 변환시켜 이용하거나 햇빛, 물, 지열, 강수, 생물 유기체 등 재생 가능한 에너지를 변환시켜 이용하는 에너지로 11개 분야를 신재생에너지로 정의하고 정부에서도 '2021년 신재생에너지 보급지원사업'을 추진하여 신재생에너지 설비 설치 비용을 일부 지원하고 있다. 이렇게 에너지 분야는 우리나라의 아주 중요한 쟁점으로 다뤄지고 있으며 신재생에너지는 화석 에너지 고갈 문제와 환경문제에 대한 핵심 해결방안이라는 점에서 그 중요성과 개발 필요성이 점차 증가하고 있다.

이렇게 신재생에너지를 중요하게 여기고 개발하고 있는 이유는 안정적인 전력을 생산하기 위해서이다. 국내 전력산업은 지속적으로 증가하는 전력 수요에 안정적으로 대처하기 위해 다양한 방법들을 활용하고 있다. 그 중 2014년 신규 개설된 수요반응(Demand Response, DR)시장은 공급 자원의 추가적인 생산과 건설을 회피하고 전력 가격 및 전력 공급의 안정 효과를 가진다. DR 시장에서 전력을 거래를 진행할 때 System Marginal Price(SMP)를 기반으로 전력을 거래하고 있다. 입찰과 낙찰을 통해 거래가 진행되는데 이 과정에서도 SMP를 사용하고 있다. 또한 태양광 발전 전력 거래 시장에서도 SMP 기반으로 거래한다. 정산을 할 때에 SMP를 기반으로 정산을 진행한다. SMP를 예측함으로써 전력 거래 낙찰에 미치는 영향을 분석하여 경제적인 이익을 확보할 수 있고, 시장의 동향을 예측하여 전력 망의 안정성에 기여할 수 있다.

## 1.2. 연구목표

본 연구는 과거의 SMP 데이터를 바탕으로 SMP를 예측하여 가시적으로 확인하여 DR 수요 거래 시장에서의 낙찰에 대한 분석을 통해 경제적인 이익을 얻어낸다. 또한 앞으로의 시장동향을 예측함으로써 전력망의 안정성을 유지하는 것이 목적이다..

첫 번째 전력거래소에 매일 업로드 되는 계통한계가격(SMP)를 수집하여 딥 러닝 모델 중 LSTM 모델을 사용하여 앞으로의 SMP를 예측한다. SMP에 크게 영향을 미치는 요소들을 파악하여 전력수요, 연료비, 유가, 기온 등의 요인들에 대해 전 처리와 변수 처리를 하고 비교를 통해 보다 정확한 예측 값을 얻어낸다. 데이터 수집은 전력거래소와 기상청에서 OPENAPI를 통해 가져온다. 가져온 SMP와 기온 데이터는 MySQL Database에 저장한다.

두 번째 실제 SMP와 예측된 SMP를 비교하기 위해 React의 AMChart를 사용해 대시보드로 구성한다. 모델에서 예측한 값을 MySQL Database에 저장 후 대시보드로 표현하여 가시성을 높이고 예측한 값이 틀린 부분을 확인한다.


세 번째 SMP가 경제성 DR 시장 낙찰에 미치는 영향을 분석하고, 이들의 예측을 통해 시장 동향을 분석한다. SMP는 경제성 DR 시장 내 수요 자원의 낙찰에 영향을 미친다. 따라서 일정 기간의 수요 자원의 시장 낙찰 결과를 분석하여 월 평균 가격 동향과 낙찰량을 분석하여 시장 동향을 파악한다.

## 2. 관련연구

### 2.1. 계통한계가격 SMP(System Marginal Price)

계통한계가격은 전력 판매자가 발전한 전기 에너지를 전력중개소를 통해 한국전력공사에 파는 가격을 의미한다.

#### 2.1.1. 가격결정방법



[그림 1] SMP의 가격결정방법

전기의 가격도 일반 상품의 가격과 마찬가지로 경쟁 시장에서 수요와 공급의 균형점에서 결정되는 원리와 같다. 우리나라의 전력시장 가격은 1 시간 단위로 전력거래 하루 전에 결정되며, 하루 전에 예측한 전력 수요와 발전사의 발전 공급 입찰이 만나는 점에서 결정된다.

즉 전력을 구매하고 싶은 구매자와 전력을 팔고 싶은 판매자가 각각 원하는 적정가격이 만나는 접점에서 거래가격이 결정된다.

## 2.1.2. SMP 가 필요한 이유



[그림 2] 정산 단가

SMP 가격은 계통한계가격으로 전력을 판매하는 판매자가 다른 에너지원으로 전기 에너지를 만들어 내기까지 비용이 발생하게 되는데 이 비용은 사용하는 발전원 별(유류, LNG, 석탄, 원전 등) 원가 비용이 다르고, 발전 시 드는 비용도 모두 다르게 된다. 따라서 발전에 드는 평균치로 적정 한계선을 정해 판매와 공급이 원활하게 하기 위해 정해놓은 가격이 필요하므로 SMP 가 필요하다.

### 2.1.3. SMP 의 변동 요인

SMP 가격 책정 원리는 발전원 별 원가 구매 비용을 가장 먼저 고려하기 때문에, 매년 달라지는 국가 유가에 가장 많은 영향을 받는다. 우리나라는 자체 생산 연료가 없고 해외에 에너지 의존도가 높기 때문에 세계 유가 시장과 정부의 에너지 정책에 많은 영향을 받는다.

### 2.1.4. SMP 의 가격결정 절차

전력거래소는 다음날 거래일의 수요를 예측하여 하루 전에 발전 업체로부터 공급 가능한 발전 용량을 입찰 받고 이를 바탕으로 1 시간 단위로 시간대를 나눠 발전계획을 수립하여 시장가격을 결정한다. 전력을 구매하고 싶은 구매자의 수요는 충족시키면서, 공급자들의 발전 비용은 최소화 할 수 있는 거래 환경을 만드는 것이다.

### 2.1.5. SMP 가 사용되는 거래



[그림 3] DR 수요거래 시장



[그림 4] 태양광발전거래 시장

SMP 는 DR(수요 거래) 시장의 정산 거래 및 태양광 발전의 매출액 거래에 사용된다. DR 수요거래시장의 경제성 DR 거래 감축 정산 시 정산금은 낙찰량에 SMP 를 곱하여 받는다. 태양광 발전 전력 거래 시장의 경우도 정산금은 발전량에 SMP 를 곱하여 매출액을 산정한다.

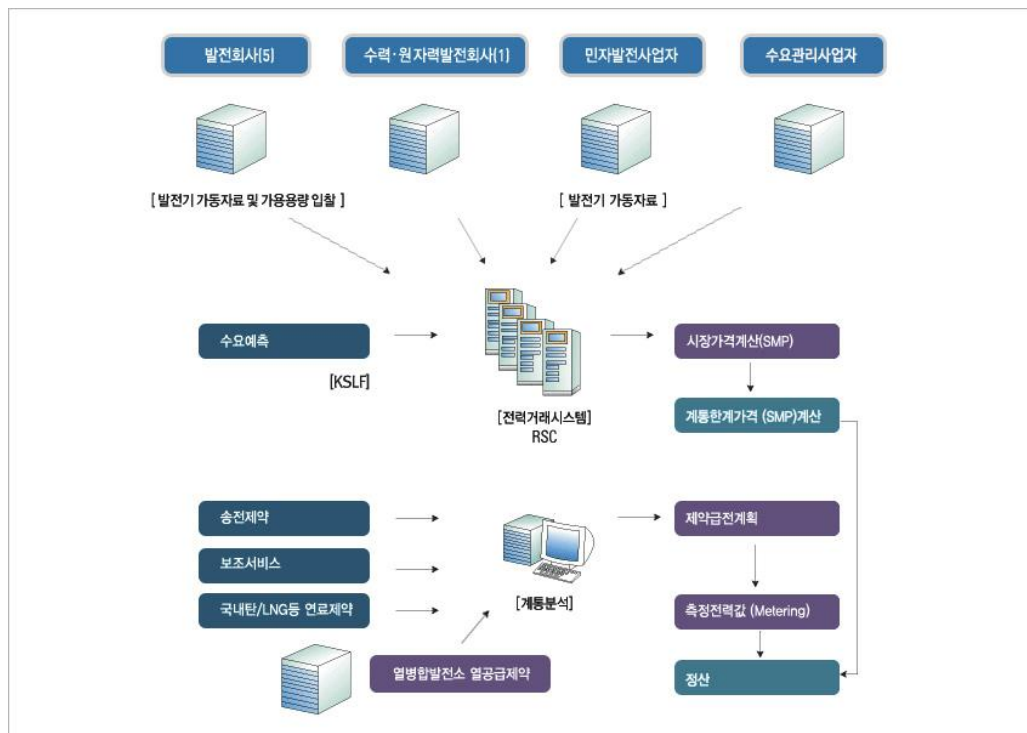
## 2.2. 전력 시장의 구조



[그림 5] 전력 시장의 구조

전력 시장은 1999 년에 시작한 전력산업 구조개편 기본계획에 따라 2001 년에 개설한 전기를 생산하고 사고파는 시장이다. 전력 시장은 전기사업법에 의거 산업통상자원부 허가를 받은 다수의 사업자로 구성되며 수요예측과 전력도매시장가격 결정 및 계통 운영을 담당하고 있는 전력거래소와 송전, 배전, 판매를 겸업하는 판매사업자인 한국전력공사, 그리고 한전 자회사 6 개, 일반 발전 사업자 등으로 구성되어 있다.

모든 전력 거래는 일부 민간 LNG 발전사, 소규모 신재생을 제외하고 전력 시장을 통해서만 가능하다. CBP(Cost Based Pool)로 이뤄진 전력 시장은 발전변동비에 기초하여 전력거래 가격이 결정되는 시장이다. 발전기별 변동비는 전력거래소 비용평가위원회에서 사전에 결정되며, 발전사는 용량만 입찰하는 구조이다. 전력 시장은 하루 전 시장(Day Ahead Market)이다. 거래 가격은 하루 전에 확정되며, 매 시간대 별 예측 수요를 충족시키는 한계 발전기의 변동비로 계통한계가격이 결정된다.



[그림 6] 전력 시장에서의 SMP

그림 6 을 통해 전력시장에서의 SMP 의 중요성과 SMP 예측 시 이익을 알 수 있다. 계통한계가격을 기반으로 정산하고 단기수요예측 시스템을 통해 수요를 예측하고 SMP 를 계산한다. 따라서 SMP 를 예측할 시 발전사의 입찰찰에 더욱 유리하게 작용한다.

## 2.3. SMP 데이터 수집

구분	09.04 (토)	09.05 (일)	09.06 (월)	09.07 (화)	09.08 (수)	09.09 (목)	09.10 (금)
1h	94.69	86.32	87.62	93.67	93.78	93.52	94.02
2h	92.09	84.38	83.57	93.07	93.07	93.07	93.07
3h	92.09	84.38	66.1	93.07	93.07	93.07	93.07
4h	92.09	84.38	66.1	93.07	93.07	93.07	93.07
5h	92.09	65.82	66.19	93.07	93.07	93.07	93.07
6h	92.09	84.38	83.57	93.07	93.07	93.07	93.07
7h	92.09	84.38	87.55	95.49	95.45	96.98	94.05
8h	92.09	84.38	97.74	99.35	98.93	99.61	98.94
9h	92.09	84.38	99.68	102.62	102.64	103.08	102.09
10h	92.09	84.38	101.84	100.79	101.7	101.71	101.93
11h	92.09	87.58	102.01	100.79	101.49	101.71	102.61
12h	92.09	87.38	102.01	100.79	101.34	101.71	102.61
13h	92.09	84.38	102.01	100.56	101.27	101.71	101.93
14h	95.95	84.38	103.97	103.84	103	103.69	105.05
15h	97.42	87.28	104.64	104.51	104.44	104.97	106.46
16h	97.42	87.45	104.64	105.66	104.92	104.94	106.46
17h	97.45	89.36	104.64	105.66	104.92	104.97	106.46
18h	97.45	97.16	104.64	105.66	104.93	105.05	104.13
19h	98.6	102.76	103.21	105.66	103.03	103.7	103.9
20h	98.86	102.88	102.01	102.38	102.3	103.37	103.68
21h	99.12	102.78	101.84	100.8	101.78	101.71	102.31
22h	99.37	98.11	99.3	99.5	99.32	99.54	102.09
23h	91.93	92.28	99.3	98.29	98.8	98.83	98.85
24h	91.93	88.15	98.39	97.91	98.01	98.74	98.85
최대	99.37	102.88	104.64	105.66	104.93	105.05	106.46
최소	91.93	65.82	66.1	93.07	93.07	93.07	93.07
가중평균	94.48	88.67	96.22	100.01	99.91	100.27	100.6

[그림 7] SMP 가격

OPENAPI						
제목	계통한계가격					
작성자	KPX					
내용	① 요청 메시지 명세					
	항목명 (영문)	항목명 (국문)	항목크기	항목구분	생물데이터	항목설명
	areaCd	지역코드	1	1	1	육지:1 제주:9
	※ 항목구분: 필수(1), 옵션(0), 1건 이상 복수건(1..n), 0건 또는 복수건(0..n)					
	② 응답 메시지 명세					
	항목명 (영문)	항목명 (국문)	항목크기	항목구분	생물데이터	항목설명
	resultCode	결과코드	2	1		결과코드
	resultMsg	결과메세지	50	1		결과메세지
	items	목록		0..n		목록
	tradeDay	거래일자	8	1	20151113	연월일
	tradeHour	거래시간대	11	1	0	시
	smp	계통한계가격	20,10	1	93.47	단위: 원
	areaCd	지역코드	1	1	1	육지:1 제주:9
	※ 항목구분: 필수(1), 옵션(0), 1건 이상 복수건(1..n), 0건 또는 복수건(0..n)					

[그림 8] 전력수급현황 공유시스템 OpenAPI

위에서 설명한 것과 같이 SMP 는 매시간 마다 하루 전에 결정된다. 따라서 데이터를 가져와야할 필요성이 있다. KPX 의 대국민 전력수급현황 공유시스템 OpenAPI 를 사용했다..

## 2.4. SMP 예측

### 2.4.1 ARIMA 를 사용한 SMP 예측


*ARIMA(p, d, q) models*

$$\phi_p(B)(1-B)^d y_t = \delta + \theta_q(B)\epsilon_t$$

[그림 9] LSTM 의 일반적인 형태

ARIMA 모델을 사용하여 SMP 를 예측할 예정이다. ARIMA 는 시계열 데이터 기반 분석 기법으로 과거의 데이터가 지니고 있는 추세까지 반영한다. 자기 자신의 과거를 사용하는 AR 모델, 트렌드가 변화하는 상황에서 적합한 MA 모델, 현재상태에서 바로 전 상태를 뺀 차분(d)을 이용할 수 있다. 시계열 데이터를 더 잘 이해하거나 미래 지점 예측하기에 적합하며 ARIMA(p,d,q)의 최적 파라미터를 찾기 위해 ACF(자기상관함수), PACF(부분 자기 상관 함수) 사용한다.

### 2.4.2. 딥러닝을 사용한 SMP 예측



[그림 10] LSTM 의 구조

LSTM 모델을 사용하여 SMP 를 예측할 예정이다. LSTM 은 RNN 에서 발생하는 vanishing , exploding gradient problem 을 해결하기 위해 제안되었다. LSTM은 gradient 관련 문제를 해결하기 위해 forget gate, input gate, output gate 라는 새로운 요소를 은닉층의 각 뉴런에 추가했다. 그림 8 을 보면 기본적인 RNN 의 구조에 memory cell 이 은닉층 뉴런에 추가된 것을 볼 수 있다. memory cell 은 추가된 3 개의 gate 를 의미한다.

LSTM 에서 Forget gate 는 과거의 정보를 어느정도 기억할지 결정한다. 과거의 정보와 현재 데이터를 입력 받아 sigmoid 를 취한 뒤에 그 값을 과거의 정보에 곱한다. 따라서, sigmoid 의 출력이 0 일 경우에는 과거의 정보를 완전히 잊고, 1 일 경우에는 과거의 정보를 온전히 보존한다. Input gate 는 현재의 정보를 기억하기 위해 만들어졌다. 과거의 정보와 현재 데이터를 입력 받아


sigmoid 와 tanh 함수를 기반으로 현재 정보에 대한 보존 량을 결정한다. output gate 는 과거의 정보와 현재 데이터를 이용하여 뉴런의 출력을 결정한다

## 2.5. 기존 연구

### 2.5.1. 기존 연구와의 연관성

**그림. 5. 2018년 하절기 예측 결과**

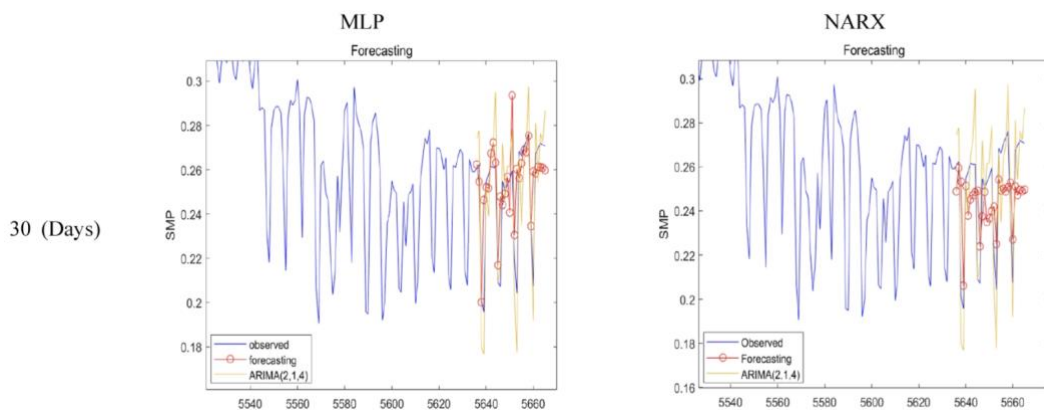
**Fig. 5. The result of prediction for summer in 2018**



**[그림 11] 딥러닝 모델 기반 단기 전력 수요 예측 결과**

기온 변화에 따른 전력 수요의 변화를 이용한 딥러닝 STLC(Short Term LSTM-CNN) 기반 단기 수요 예측 모델 제시한다. 이 연구에서는 2013~2017 년까지의 전력 수요 데이터와 가중치를 반영한 기후데이터(기온, 습도, 이슬점 온도) 사용하고 있다. 이 연구를 바탕으로 기온을 기반으로 한 SMP 예측 연구를 진행한다.

### 2.5.1. 기존 연구와의 차이점



**[그림 12] Multilayer Perceptron(MLP), Nonlinear Autoregressive exogenous(NARX) 모형을 이용한 계통한계가격(SMP) 예측 결과**


스스로 데이터를 학습하는 알고리즘을 통해 다양한 문제에 적용 가능한 인공지능망 사용한 연구이다. 전방향 인공지능망중 많이 사용되는 MLP, 시계열 데이터에 유용하게 사용되는 NARX를 이용하여 서로 비교 분석한다. SMP는 시계열 데이터이기 때문에 LSTM이 더 효과적이라 판단하여 Hybrid ARIMA LSTM을 이용하여 SMP를 예측한다.




- 기상청의 종관기상관측 자료에서 일별 제주 지역의 최고, 최저, 평균 데이터를 수집하여 MySQL 에 저장한다. 2010.01.01~2021.11.17 까지의 데이터를 사용했다.

### 3.1.2. 데이터에 대한 분석


SMP 평균, 전력수요, 기온 데이터에 대한 분석을 진행한다.




[그림 15] SMP 와 Supply, Weather 의 상관관계



[그림 16] 기온데이터의 주기적인 특성



[그림 17] supply 데이터의 주기적인 특성



[그림 18] SMP 평균 데이터의 그래프

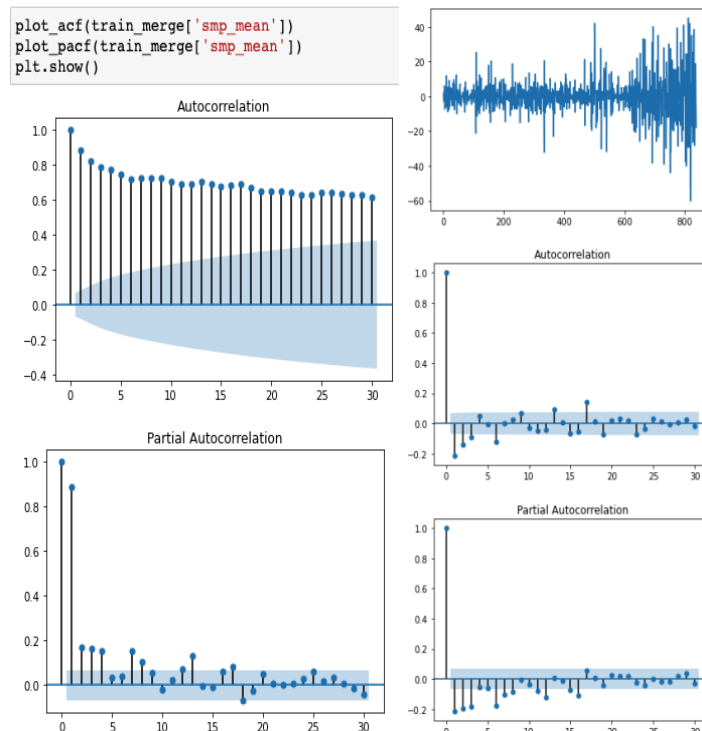
### 3.1.3. 데이터 전처리

분석한 데이터에 없는 데이터의 처리와 어떤 데이터를 사용하여 모델을 구성할 것인지 결정 후 모든 데이터를 통합하여 관리한다. Supply 데이터의 경우 중간 값이 빈 경우가 있어 앞 뒤 평균으로 구했고 나머지 데이터는 그대로 가져와서 통합을 진행한다.

	date	smp_min	smp_max	smp_mean	temp_mean	temp_max	temp_min	facility_capacity	supply_ability	pre_supply	supply
0	2010-01-01	146.94	174.02	157.70	3.800	8.075	0.750	82.129997	71.500000	49.200001	51.000000
1	2010-01-02	147.44	159.51	153.33	9.450	15.150	3.750	82.129997	71.500000	50.500000	51.000000
2	2010-01-03	148.40	176.15	158.78	4.775	7.200	2.350	82.150002	71.500000	48.500000	51.000000
3	2010-01-04	150.18	168.55	161.65	7.700	13.500	2.275	82.150002	71.500000	47.200001	54.000000
4	2010-01-05	155.30	290.69	169.82	1.825	4.275	0.775	82.150002	79.400002	50.400002	56.000000
...	...	...	...	...	...	...	...	...	...	...	...
4334	2021-11-13	116.71	215.51	152.62	13.375	17.000	10.400	174.179993	134.639999	68.480003	73.190002
4335	2021-11-14	72.75	185.57	143.58	15.025	19.525	11.350	174.179993	135.679993	66.690002	71.790001
4336	2021-11-15	137.68	195.43	170.63	13.850	18.325	10.425	174.179993	126.489998	70.160004	75.389999
4337	2021-11-16	137.68	210.14	168.60	13.450	17.100	10.625	174.179993	133.960007	69.820000	76.669998
4338	2021-11-17	137.51	267.09	177.54	13.375	17.325	9.525	174.179993	125.930000	70.120003	76.269997

[그림 19] 데이터 통합

### 3.1.6. ARIMA Model 개발




[그림 20] ACF, PACF 를 사용한 ARIMA 의 모수(1 차 차분)

ARIMA 모델을 구현할 때 시계열이 시간의 추이와 관계없이 평균 및 분산이 불변하거나 시점 간의 공분산이 기준시점과 무관한 형태가 아닌 경우 로그를 이용하거나 차분을 이용하여 시계열을 안정적으로 변환한 뒤 분석을 진행한다. 왼쪽 그림을 보면 ACF가 시간에 무관하게

양의 값을 가지고 있고 PACF 는 1 의 타임랙에서 0.9 를 가지고 급격히 감소한다. 따라서 1 차 차분을 진행하여 모수를 0,1,1 로 ARIMA(0,1,1) 모델을 사용한다. 검증 데이터는 전체 데이터의 30%를 사용하고 과거의 데이터로 7 일~28 일 뒤의 SMP 값을 예측하는 과정을 반복하여 진행한다. 그 결과값을 저장한 뒤 그래프로 표현한다.

### 3.1.5. LSTM Model 개발



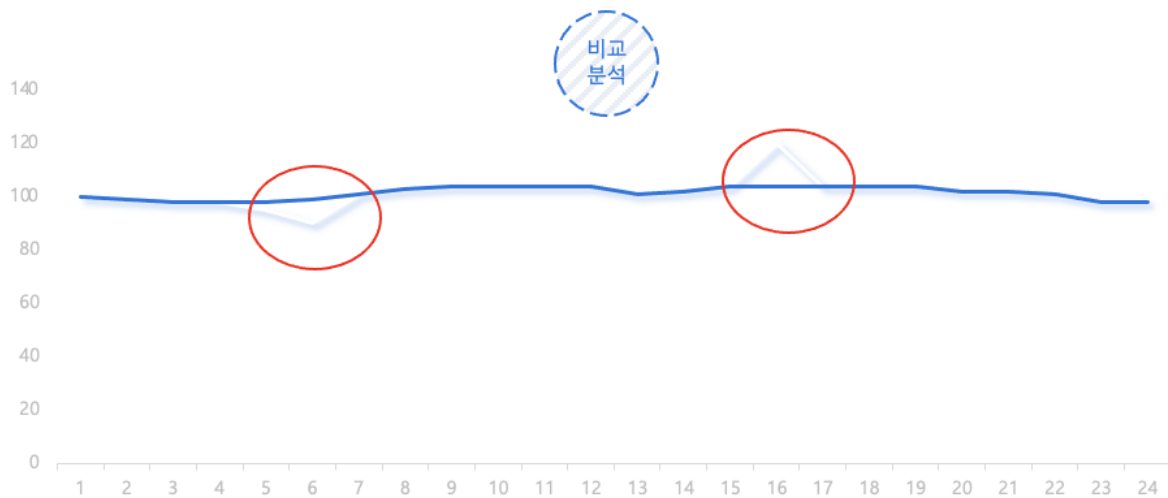
[그림 20] LSTM 모델 구조

미래의 SMP 를 예측하는 딥러닝 모델을 개발한다. 학습데이터는 전체 데이터의 70%, 검증 데이터는 전체 데이터의 30%로 사용한다. LSTM 은 시간적으로 correlation 이 있는 데이터를 처리하기 위해 사용하는 딥러닝 모델이다. 일정 기간의 Long Term memory 로 7 일~28 일 뒤의 SMP 를 예측하기 위해 사용한다.

### 3.1.6 Dashboard 구성

실제 SMP 와 예측 SMP 를 대시보드로 표현한다.

### 3.1.7 결과 데이터 분석



예측한 데이터와 실제 데이터 값의 차이가 어느 요인으로 인해 발생했는지 매우 유사, 유사, 큰 오차에 대해 수치화를 진행하고, 다른 방식으로 데이터를 전처리하거나 딥러닝 모델을 수정하여 데이터를 분석한다.

## 3.2. 요구사항

### 3.2.1. SMP 데이터에 대한 요구사항

- 기간에 대한 정확한 설정이 필요하다. → 2010.01.01 ~ 2021.11.17
- 학습 데이터와 검증 데이터를 고정하고 여러 요인에 대해서 먼저 분석 후 예측한 값이 정확도가 높다고 판단될 때 다른 기간으로 다시 예측을 진행할 필요성이 있다.

### 3.2.2. 딥러닝 모델에 대한 요구사항

- Tensorflow, numpy 등의 라이브러리와 버전 호환성을 확인한다.
- 다른 모델을 사용했을 때 예측한 값과 비교의 필요성이 있다.
- Hybrid ARIMA LSTM 모델만의 장점에 대해서 파악한다.
- ARIMA를 통해서 예측했을 경우를 확인한다.
- LSTM 모델을 사용해서 예측했을 경우를 확인한다.


### 3.2.3. 데이터 분석에 대한 요구사항

- 딥러닝 모델을 통해 예측된 데이터가 실제 SMP와의 오차에 대해 수치화한다.

- 대시보드를 통해 가시적으로 표현된 데이터가 어떤 요인에 의해 오차가 발생하였는지 분석한다.
- 대시보드에 유가의 정보가 포함될 수 있다면 추이를 파악하기 위해 표시를 진행한다.
- 유가와 전력 가격의 관계에 대해서 심도 깊은 분석이 필요하다. 대칭적으로 이뤄지는지 확인하고 유가 변동에 의한 SMP 가격의 변화에 대해서 분석이 필요하다.
- 기온과의 관계에 대해서 파악해야 한다.
- 전력 수급 실적과의 연관 관계에 대해서 파악해야 한다.

### 3.3. 시스템 설계

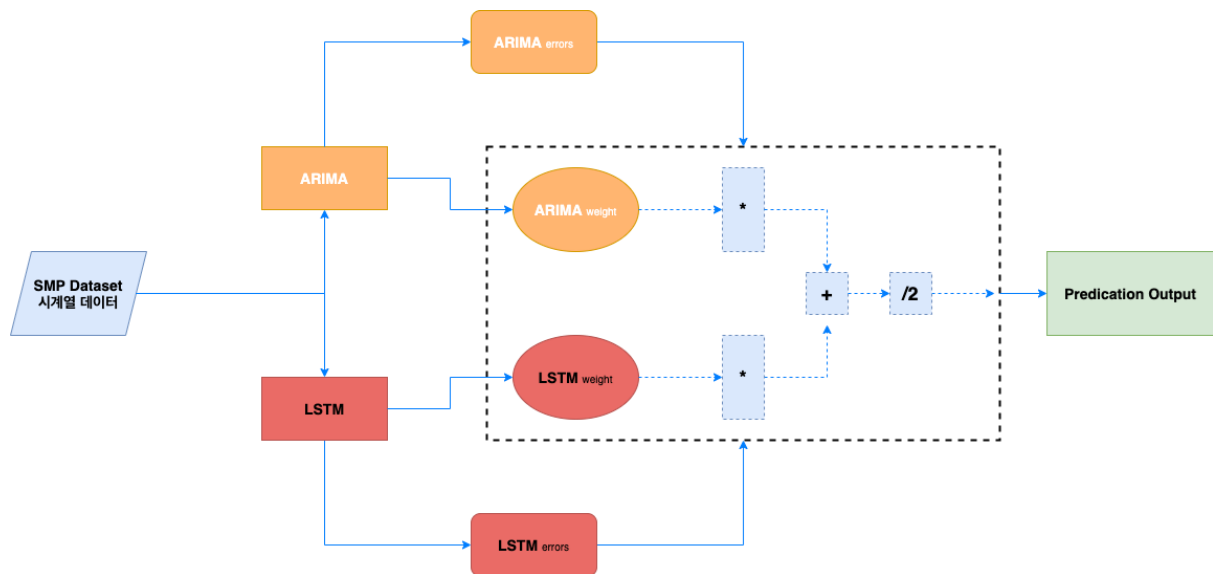
#### 3.3.1. 시스템 구성도



[그림 21] 시스템 구성도

시스템 구성도는 [그림 21]과 같다.

#### 3.3.2. Hybrid ARIMA-LSTM 딥러닝 모델 구조



[그림 22] Hybrid ARIMA LSTM 딥러닝 모델 구조

ARIMA 모델과 LSTM 모델을 합친 모델로 ARIMA 와 LSTM 모델을 각각 학습한 후 평균을 내어 구한다. ARIMA 를 통해 과거 수요 데이터의 특징을 포함하는 통계적으로 예측된 데이터를 생성하고 LSTM 모델과 결합하여 신경망 모델이 가지는 장기적인 의존성 문제 회피, 유연성 등이 구성된 구조를 통해 정확한 예측을 할 수 있다.

### 3.4. 구현

소스코드 경로 및 폴더 구성은 아래와 같다.

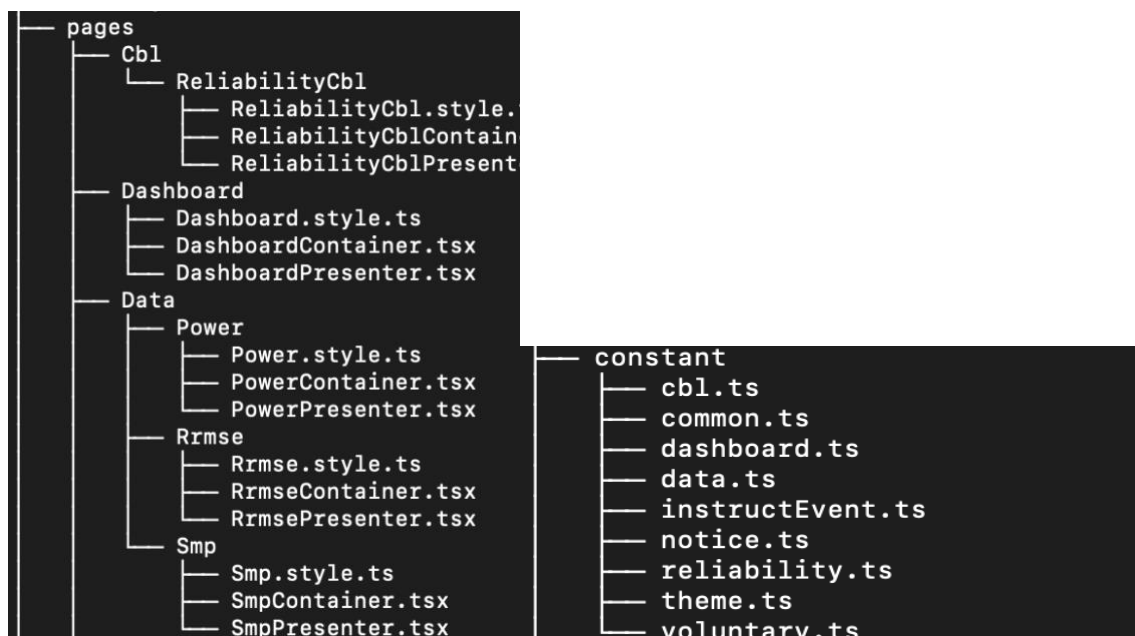
#### 3.4.1. 딥러닝 모델 구현

딥러닝 모델을 구축하기 위한 것은 Jupyter 노트북을 통해 진행했다.

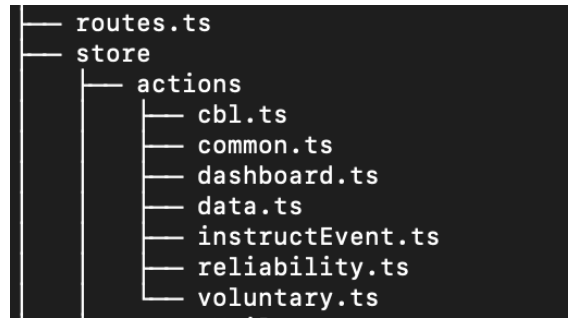


[그림 23] 모델 구현

#### 3.4.2. 대시보드 구성







[그림 23] 대시보드 구조


React 로 대시보드를 구성하였고 위부터 시계방향으로 DRMS 대시보드에 들어가는 SMP 페이지 파일 API 를 연결하고 데이터를 불러오는 Container 파일, 차트 뷰를 구성하는 Presenter 파일, CSS 를 설정하는 style 파일, 오른쪽 그림의 constant 의 경우 데이터의 타입을 설정하는 파일로 구성되어 있다. 아래 store - action 파일에서는 data 에 작업을 진행하였고 Redux 를 사용하여 상태 관리를 진행하였다. L

## 4. 프로젝트 결과

### 4.1. 연구 결과

#### 4.1.1. SMP 예측

SMP 를 Hybrid-ARIMA LSTM 딥러닝 모델로 예측 가능하다. 시각화를 통해 DRMS 입낙찰에 영향을 미치는 SMP 의 시장동향을 파악하여 전력망 안정성에 기여할 수 있다.



[그림 24] Hybrid ARIMA LSTM 모델 SMP 예측 결과

#### 4.1.2. 대시보드 구성

대시보드로 구성하여 고객에게 가시성 높은 그래프를 제공할 수 있으며 앞으로의 시장에 대해 예측하고 전력 망의 안정성에 기여함으로써 에너지 시장에 기여할 수 있다.

## 4.2. 성능평가

성능 평가는 RMSE 기법을 사용하여 각 모델에 대한 성능을 평가하였다.

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

[그림 19] RMSE 공식

예측값과 실제값을 뺀 후 제곱시킨 값들을 다 더한 후 n 으로 나누고 루트를 씌우는 것으로 평균 제곱근 편차, 표준편차라고 생각하면 된다. 모델이 잘 트레이닝 되었는지 판단하는 기준으로 RMSE 를 사용했다.

## 5. 결론

### 5.1. 기대효과

해당 연구를 통해 Hybrid ARIMA LSTM 모델을 이용해서 SMP 를 예측할 수 있는 것을 알 수 있다. 또한 SMP 의 예측은 미래가격변화에 대한 정확도에 따라 경제적인 이익을 극대화할 수 있다. DR 수요 거래 전력 시장이 경쟁체제이므로 SMP 의 추정 및 예측은 매우 중요한 것을 알 수 있다. 경제성 DR 시장의 낙찰에 SMP 의 영향을 확인하여 분석함으로써 고객의 이윤을 극대화 할 수 있다.

딥러닝 모델을 기반으로 예측 결과를 기반으로 정확도를 분석하여 시장 동향을 예측할 수 있다. SMP 가격을 결정하는데 여러 요인이 있다는 것을 확인할 수 있다. 여러 요인들에 대해 가중치 혹은 전처리를 통해 어떤 요인이 가장 예측 값에 영향을 미치는지 모델 개선에 있어서 어떤 점을 잘 파악하고 데이터를 수집해야 하는지 알 수 있다. 또한 그 중에서 원유가 가장 큰 이유와 SMP 움직임에 대해서 예측할 가능성이 높아질 것이다.

### 5.2. 추후 연구 방향

추 후에 더 정확한 예측을 위해 유가가 반영되도록 모델을 조정할 필요성이 있다. SMP 의 경우 공휴일이나 특수일과 같은 여러 제외되는 일이 발생하는데 이는 API 를 통해서 개선할 필요성이 있다. LSTM 모델 뿐만이 아닌 다양한 알고리즘을 연구하고 비교 적용하는 것이 필요하다. 단순히

LSTM 모델만 연구하는 것이 아닌 인공지능망 딥러닝 모델들을 사용하여 적합하다고 생각되는 모델들을 통해 연구를 더욱 진행할 필요성이 있다.

## 6. 참고문헌

- [[1] 김형태, 이성우, 김규민, 권민성, 김욱, 정해성. System Marginal Price Forecasting using SUDP Algorithm. SUDP 알고리즘을 이용한 SMP 예측에 관한 연구. 대한전기학회. 2012.10, 424-426
- [2] 안일환, 강승진. An Empirical Analysis of the System Marginal Price Volatility in the Korean Electricity Wholesale Market. 한국 전력도매시장(CBP) 계통한계가격(SMP) 변동성 실증분석. 2014.9, 103-129
- [3] 김도영, 정현철, 강병오. Trend analysis of the Economy DR Market Based on Predicting NBTP and SMP. NBTP 와 SMP 예측을 통한 경제성 DR 시장 동향분석. 대한전기학회. 2019.7, 142-143
- [4] 양민승, 이성무. A Study on Economic Demand Response NBT and Performance. 우리나라 전력시장에서 경제성 DR 의 NBT 및 낙찰 관계 분석. 한국태양광발전학회. 2017.9, 100-104
- [5] 정수관, 원두환. Relation between Oil Prices and Electricity Prices. 원유가격과 전력가격의 연계성. 에너지경제연구원. 2020.3, 153-176
- [6] 정수관, 김형건, 원두환. A Study on the Effect of SMP Volatility on Power Supply in Korea. 전력공급에 대한 계통한계가격 변동성의 영향 분석. 한국산업경제학회. 2018.6, 1057-1077
- [7] 박지현, 나완수, 쑤안. Evaluation of demand power prediction performance based on deep learning algorithm and data preprocessing. 딥러닝 알고리즘과 데이터 전처리에 따른 수요전력 예측 성능 평가. 한국정보과학회. 2017.06, 1882-1884